Introduction à la recherche

Rapport individuel

Le Quéré Damien

Equipe de Traitement Automatique des Langues
Encadrants : Fabien Poulard & Nicolas Hernandez

29 mai 2009

Table des matières

1 Introduction **3**

2 Contexte du stage **4**
2.1 Le sujet 4
2.2 Le domaine de recherche 4
2.3 L'équipe de recherche 5

3 Mon bilan sur le travail de recherche **6**
3.1 Mode de fonctionnement 6
3.2 Approche scientifique 7

4 Conclusion **8**

Chapitre 1

Introduction

Le master ALMA a le double objectif de préparer ses étudiants à l'insertion professionnelle et à la recherche. Dans ce contexte, le module d'introduction à la recherche doit nous permettre de nous familiariser avec le travail de recherche en informatique en nous intégrant à un travail de recherche au sein d'une équipe de chercheurs, et ce durant quatre mois.

Ce rapport présente mon bilan personnel de ces quatre mois selon deux parties : le contexte du stage, et mon analyse de la méthode de travail d'un chercheur.

Chapitre 2

Contexte du stage

2.1 Le sujet

Nous sommes quatre étudiants à avoir choisi le sujet suivant : *"La résolution d'anaphores pronominales dans le cadre de la détection de citations"*, Floriant Barbin, Victor Picault, Myrtille Ponge et moi-même.

Ce sujet se rattache au travail réalisé par Fabien Poulard (présenté dans la partie 'L'équipe de recherche') concernant le problème de la détection de citations dans des articles journalistiques. Le principe est de reprendre le travail déjà réalisé et d'étendre ses fonctionnalités.

Exemple : **Jacques Chirac** a rencontré Jean Pierre Raffarin, il lui a assuré qu'il allait faire beau. "Je ne pourrais pas supporté qu'il en soit autrement" a-t-**il** ajouté.

Ici le travail de Fabien Poulard permet de repèrer les composants de la citation que sont le texte entre guillemets (discours repris) et le pronom 'il' (expression locuteur) le suivant.

Notre tâche principale a été d'ajouter au traitement l'association entre le discours repris et l'entité nommée 'Jacques Chirac' pour être capable de déterminer qui dit quoi, pour cela il nous a fallut résoudre des anaphores pronominales c'est à dire savoir à quelle entité nommée correspond le pronom 'il'. Il nous a aussi fallu réimplémenter le travail déjà effectué sur une nouvelle plate-forme.

2.2 Le domaine de recherche

Le problème de la résolution d'anaphores est un problème du domaine du traitement automatique des langues (TAL). Le TAL est défini par l'ensemble

des méthodes et des programmes qui prennent pour données des productions langagières (textes, enregistrement vocal,...) quand ces programmes ou méthodes tiennent compte des spécificités des langues. Cette discipline rejoint différents domaines tels que la linguistique, l'informatique et l'intelligence artificielle. Voici quelques exemples d'applications du TAL :

- La traduction automatique
- La correction automatique
- Le résumé automatique de texte
- La reconnaissance vocale
- La détection de plagia (un des objectifs finaux de notre sujet)

2.3 L'équipe de recherche

L'équipe travaillant sur le sujet est composée de deux personnes, Fabien Poulard[1] (Doctorant) et sont encadrant Nicolas Hernandez[2]. Ils appartiennent tous les deux à l'équipe TAL du laboratoire d'informatique de Nantes Atlantique[3] (LINA).

[1] `fabien.poulard@univ-nantes.fr`

[2] `nicolas.hernandez@univ-nantes.fr`

[3] Le laboratoire d'informatique de Nantes Atlantique est un laboratoire en "sciences et technologies du logiciel" avec un effectif global de 165 membres. Il couvre deux axes de recherche : les architectures logicielles distribuées et les systèmes d'aide à la décision

Chapitre 3

Mon bilan sur le travail de recherche

Durant les quatre mois du stage à raison d'une journée et demie par semaine, mon groupe de recherche a travaillé sur la résolution d'anaphores en adoptant le mode de fonctionnement d'un chercheur. Cette partie du rapport explique mon approche du travail de recherche.

3.1 Mode de fonctionnement

Sur tous les projets dont nous avons entendu parlé au LINA, la recherche s'effectue en équipe. Le travail d'équipe peut s'effectuer localement comme c'est le cas de l'équipe à laquelle nous avons été affectés, ou via un réseau comme Internet pour des équipes dispersées géographiquement.

Pour déterminer ses objectifs, et pour faire le point sur le travail accompli les équipes se réunissent régulièrement. Pour mon groupe les réunions étaient hebdomadaires et nous ont souvent évité de nous égarer sur des problèmes hors-sujet. Ces réunions forcent aussi au travail de synthèse puisqu'il s'agit d'expliquer le travail effectué durant une période et ainsi le mettre en perspective par rapport au problème original.

Pour présenter ses travaux un chercheur organise des conférences au sein de son laboratoire. Nous avons assisté à une conférence de Fabien Poulard (notre encadrant préparant son doctorat) devant l'équipe de Traitement Automatique des Langues. Ces conférences permettent à l'ensemble de l'équipe (de TAL) de suivre l'évolution des travaux de chacune des sous-équipes, cela permet dans un même temps d'avoir des critiques extérieures sur un projet et d'expliquer ses choix.

3.2 Approche scientifique

Le travail de recherche sur un problème donné s'effectue pratiquement toujours selon les phases suivantes :

1. Le travail bibliographique, la recherche de publications pour appréhender l'état de l'art concernant la problématique mais aussi pour avoir un aperçu des sous-problèmes quelle comporte. Cette phase est très longue et très importante pour ne pas aboutir sur un échec. Dans notre cas le travail bibliographique et le recadrage du sujet ont occupé à eux seuls plus de 80% du temps.
2. Après avoir cerné le sujet, soit on utilise une solution existante découverte avec le travail bibliographique effectué, soit on propose une solution nouvelle. La première phase doit bien sûr avoir été suffisament poussée pour ne pas réinventer une solution déjà proposée.
3. En recherche informatique et plus particulièrement en TAL, les productions des chercheurs sont souvent des méthodes, des approches d'un problème donné. La phase suivante consiste donc à implémenter un programme mettant en oeuvre leur méthode afin de prouver sont efficacité ou sont inefficacité à défaut de preuve formelle (c'est particulièrement le cas en TAL où la plupart des méthodes ne sont pas exactes à 100%)

   Je trouve que dans mon groupe le travail a été partagé assez efficacement selon les préférences de chacun, et la phase d'implémentation a été facilitée par la création d'un dépôt SVN auquel tous les membres ont participé.
4. Ensuite une phase d'*évaluation* de la méthode/du programme selon un protocole bien définie.
5. Enfin l'analyse des résultats, discussion sur la pertinence de la solution.
6. Publication du travail effectué

Il nous a été demandé pour le module d'introduction à la recherche un rapport sur notre travail, nos encadrants nous ont à cette occasion présenté les différences entre un rapport de projet comme nous en avons l'habitude, et un rapport de type " publication".

Le premier présente le cheminement des idées selon un ordre chronologique et avec explication assez précise de l'implémentation.

Le second est plus verbeux, il contient une introduction au sujet plus importante, la définition des termes spécifiques, une phase d'analyse des résultats plus poussée et peu de détails sur l'implémentation.

Chapitre 4

Conclusion

Je concluerai en listant les compétences qui selon moi sont indispensables au travail de recherche en informatique au regard du stage que j'ai effectué durant quatre mois.

- Être passionné, pour maîtriser suffisemment un domaine et être reconnue il faut de nombreuses années de travail exclusivement sur ce domaine sans aucune garantie de succès.
- Savoir travailler en équipe étant donné qu'un chercheur travaille quasiment toujours selon ce mode.
- Avoir un esprit de synthèse pour être capable d'expliquer son point de vue aux autres membres de l'équipe, pour assimiler de grande quantités de connaissances et pour rédiger des publications. Avoir un esprit synthétique permet de fixer les limites d'un problème que l'on veut résoudre et d'éviter le travail hors-sujet.

Ce stage d'introduction à la recherche s'est globalement bien déroulé même si techniquement la solution que nous avons proposé n'est pas la meilleure du fait du manque de temps impartie au module.

Merçi à nos encadrants de nous avoir fourni un sujet formateur et particulièrement bien préparé pour des étudiants n'ayant aucune expérience de la recherche.